Actividad Unidad 4: Diseño experimental y formulación del proyecto integrador

Detección y localización de anomalías industriales: comparación experimental de modelos convolucionales bajo restricciones computacionales

Diana Marcela Gómez Gamez
Facultad de Ingeniería, Universidad de la Sabana

Técnicas Avanzadas de Modelado en IA

Oscar Alberto Rodríguez Meléndez

25 de octubre de 2026

Universidad de La Sabana

Tabla de contenido

Tabla de contenido **2**
Lista de tablas **3**
Lista de figuras **3**
Resumen 3
Problema y alcance 4
Pregunta de investigación 4
Dataset, particiones y auditoría de calidad 5
Origen y características 5
Auditoría 6
Particiones 6
Riesgos de sesgo 7
Diseño experimental 8
Modelos, variantes e hipótesis 8
Hipótesis 8
Métricas 9
Métricas principales 9
Métricas complementarias de detección 10
Métricas complementarias de localización 10
Métricas de eficiencia computacional 11
Criterio de selección 11
Entorno, presupuesto y reproducibilidad 11
Entrenamiento y validación 12
Autoencoder 12
PatchCore 13
Doble U-Net 14
Evaluación final y comparación cuantitativa con la línea base 16
Resultados de detección y localización 16
Desempeño por categoría 17
Generalización: validación sintética frente a test real 17
Eficiencia computacional 19
Contraste de H4 y selección del método 19
Análisis de errores 20
Limitaciones y oportunidades de mejora 21
Conclusiones 22
Referencias bibliográficas 23

Universidad de La Sabana

Lista de tablas

Tabla 1. Características del dataset....5
Tabla 2. Modelos, variables experimentales e hipótesis....8
Tabla 3. Secuencia documentada de trabajo....12
Tabla 4. Autoencoder, promedio de 15 categorías en validación sintética....12
Tabla 5. PatchCore, promedio de 15 categorías en validación sintética....14
Tabla 6. Doble U-Net, promedio de 15 categorías en validación sintética....15
Tabla 7. Efecto principal de las variantes....16
Tabla 8. Comparación global de los modelos en el conjunto test....16
Tabla 9. Image-AUROC por categoría en el test....17
Tabla 10. Comparación del desempeño entre validación sintética y test....17
Tabla 11. Comparación de eficiencia de los modelos seleccionados....19
Tabla 12. Casos representativos de las matrices de confusión....20
Tabla 13. Limitaciones identificadas y oportunidades de mejora....21

Lista de figuras

Figura 1. Distribución de imágenes por categoría y partición....6
Figura 2. Distribución de entrenamiento y validación....7
Figura 3. Curvas de pérdida de entrenamiento del Autoencoder con funciones MSE y L1....13
Figura 4. Comparación de Image-AUROC y AUPRO por categoría y relación entre el tamaño del coreset y el tiempo de ajuste....14
Figura 5. Curvas de pérdida e Image-AUROC de validación para Small y Large....15
Figura 6. Comparación de Image-AUROC y AUPRO de los tres modelos en test....16
Figura 7. Comparación de Image-AUROC y AUPRO entre validación sintética y test....18
Figura 8. Comparación del tiempo de ajuste, latencia p95 y FPS de los tres modelos....19
Figura 9. Aciertos y errores de clasificación de los tres modelos en cuatro categorías....21

Resumen

Se compararon tres enfoques para la detección y localización de defectos industriales utilizando el dataset MVTec AD: un Autoencoder convolucional, definido como línea base; PatchCore con ResNet18 preentrenada, basado en características y un banco de memoria normal; y un sistema de reconstrucción y segmentación con dos U-Net, entrenado con anomalías sintéticas. El conjunto contiene 5.354 imágenes distribuidas en 15 categorías; se respetó el conjunto de test oficial y se obtuvo una partición de 2.903 imágenes normales de entrenamiento y 726 de validación. Se evaluaron dos variantes por método y categoría (90 configuraciones); se seleccionaron 45 detectores exclusivamente mediante Image-AUROC sobre validación sintética y se evaluaron una vez sobre defectos reales.

En la evaluación utilizando el conjunto de test, PatchCore obtuvo Image-AUROC macro de 0,9203 y AUPRO macro de 0,9088, frente a 0,6889 y 0,4367 del Autoencoder y 0,7655 y 0,5865 de Doble U-Net. PatchCore lideró la localización en las 15 categorías y la detección en 11. El Autoencoder presentó la menor latencia p95 media de 3,50 ms, frente a 13,20 ms de PatchCore. Doble U-Net mostró una reducción marcada entre validación sintética y test real, particularmente en localización. En consecuencia, se seleccionó PatchCore para priorizar calidad de detección y localización.

Problema y alcance

La inspección visual industrial requiere identificar imágenes de productos con defectos y en lo posible señalar la región afectada. En numerosos escenarios se dispone de abundantes imágenes normales, pero de pocos defectos representativos, lo que dificulta el entrenamiento supervisado convencional. Este proyecto estudia la detección de anomalías a partir de la apariencia normal y compara métodos con diferentes requisitos de entrenamiento e inferencia.

Pregunta de investigación

Bajo un mismo conjunto de categorías, particiones, resolución de entrada y protocolo de evaluación ¿qué modelo ofrece el mejor desempeño de detección y localización de defectos reales y qué costo computacional exige?

Se implementaron tres modelos en las 15 categorías de MVTec AD. El estudio comprende preparación y auditoría de datos, ajuste y validación de variantes, selección de checkpoints, evaluación sobre el test, análisis y revisión visual de errores.

La línea base es un Autoencoder CNN entrenado desde cero. PatchCore y Doble U-Net se contrastan contra esa referencia: PatchCore aprovecha pesos externos de ImageNet y Doble U-Net utiliza etiquetas artificiales obtenidas de las anomalías sintéticas.

Dataset, particiones y auditoría de calidad

Origen y características

Se utilizó **MVTec AD** un conjunto de referencia para inspección visual industrial que incluye imágenes normales de entrenamiento, imágenes normales y defectuosas de test y máscaras de los defectos. La publicación original documenta 5.354 imágenes y 15 categorías de objetos y texturas (Bergmann et al., 2019). Además de constituir la fuente de datos, el trabajo original compara métodos de reconstrucción y modelos preentrenados.

Tabla 1. Características del dataset

Característica	Resultado
Categorías	15
Imágenes totales	5.354
Entrenamiento - normal	3.629
Test	1.725
Imágenes defectuosas en test	1.258
Imágenes normales en test	467
Imágenes normales para ajuste del proyecto	2.903
Imágenes normales para validación del proyecto	726
Muestras de validación sintética (normales + anomalías)	2.178

Las categorías son bottle, cable, capsule, carpet, grid, hazelnut, leather, metal_nut, pill, screw, tile, toothbrush, transistor, wood y zipper. Algunas contienen objetos y otras texturas; su variabilidad impide interpretar un promedio global como representativo de todas las dificultades visuales.

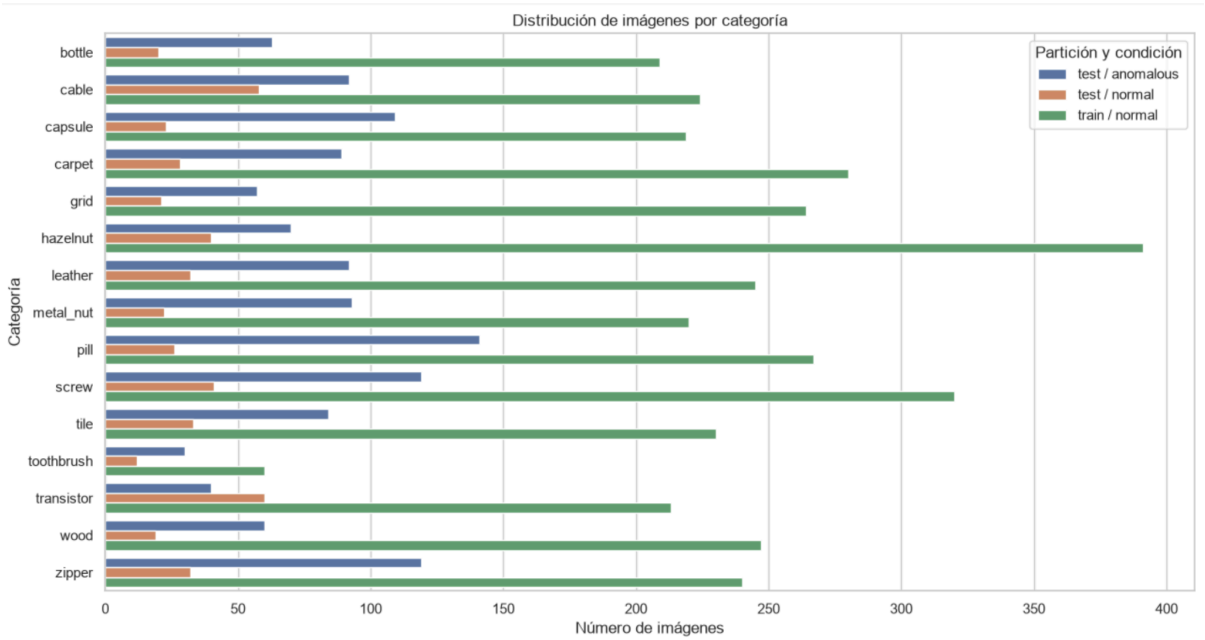


Figura 1. Distribución de imágenes por categoría y partición

Auditoría

La auditoría verificó las 15 categorías, la integridad de las máscaras correspondientes a anomalías, la coherencia de dimensiones entre máscaras e imágenes y la presencia de máscaras vacías. Los registros de auditoría consignaron cero máscaras faltantes, cero discrepancias de dimensiones y cero máscaras vacías, así como seis resoluciones distintas en el conjunto original. La inspección de duplicados exactos mediante hash SHA-256 no encontró coincidencias exactas en los archivos analizados. Esta última prueba no descarta imágenes visualmente casi idénticas.

Las imágenes se redimensionaron a 256 × 256 píxeles para estandarizar la entrada. Las imágenes RGB utilizaron interpolación bilineal y las máscaras binarias interpolación por vecino más cercano, con el fin de preservar etiquetas discretas. Los tensores se normalizaron al intervalo [0, 1]; PatchCore aplicó adicionalmente la normalización compatible con su backbone preentrenado.

Particiones

Se preservó el conjunto de test. Las 3.629 imágenes normales de entrenamiento de MVTec AD se dividieron con semilla 1926, aproximadamente 80 % para ajuste (2.903) y 20 % para validación (726). Sobre cada imagen normal de validación se conservaron una muestra

normal y dos versiones con anomalías generadas artificialmente: CutPaste (Li et al., 2021) y textura irregular localizada. La implementación propia usa esta técnica de perturbación para generar ejemplos, sin reproducir el método completo de aprendizaje autosupervisado propuesto por Li et al. El conjunto común de validación contiene 2.178 registros y utiliza la semilla 1926 para su generación reproducible.

Doble U-Net entrenó con anomalías sintéticas producidas a partir de imágenes del subconjunto de ajuste. Autoencoder y PatchCore se ajustaron exclusivamente con las imágenes normales. Esta separación reduce la fuga directa de información y etiquetas del test, aunque no elimina el posible sesgo de mecanismo sintético a favor de Doble U-Net.

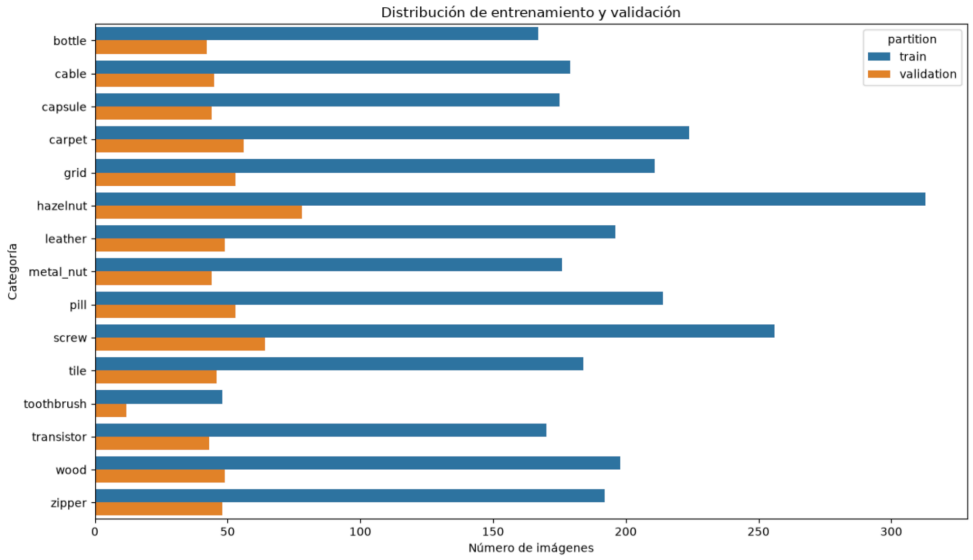


Figura 2. Distribución de entrenamiento y validación

Riesgos de sesgo

Los principales riesgos del estudio incluyen las diferencias entre categorías, el uso de una única fuente de datos, las discrepancias entre defectos sintéticos y reales, la ventaja del preentrenamiento de PatchCore, la pérdida de detalle por reducción de resolución y la dependencia de la calibración respecto a los datos de validación. Estos riesgos se mitigaron parcialmente mediante particiones fijas, un protocolo común, evaluación por categoría y documentación de las condiciones experimentales, aunque persisten limitaciones para generalizar los resultados.

Diseño experimental

Modelos, variantes e hipótesis

Para la detección y localización de anomalías, se compararon mecanismos diferentes. Los tres detectores producen un mapa de anomalía por imagen y la puntuación de clasificación se definió de manera común como el máximo valor de ese mapa.

Tabla 2. Modelos, variables experimentales e hipótesis.

Modelo	Arquitectura y entrenamiento	Variable experimental	Hipótesis
M1. Autoencoder CNN (línea base)	Encoder–decoder convolucional, canales 16–32–64, entrenado sobre imágenes normales	Pérdida: MSE o L1	H1: la pérdida influye en detección y localización
M2. PatchCore	ResNet18 congelada de ImageNet, características layer2 y layer3, vecinos más próximos	Memoria: 1 % o 5 % por coreset aproximado	H2: ampliar memoria mejora calidad, con mayor costo
M3. Doble U-Net	U-Net reconstructora seguida de U-Net segmentadora, anomalías artificiales, pérdida L1 + BCE/Dice	Small 16–32–64 Large 16–32–64–128	H3: mayor capacidad mejora desempeño, a cambio de tiempo
Comparación global	Variantes seleccionadas por validación	Calidad y eficiencia sobre defectos reales	H4: PatchCore ofrece el mejor compromiso de calidad de detección - localización frente a las alternativas

Hipótesis

A. **H1. Función de pérdida del Autoencoder.** La función de pérdida de reconstrucción (MSE o L1) influye en la capacidad del Autoencoder para detectar y localizar anomalías. La hipótesis se evalúa comparando los resultados de Image-AUROC y AUPRO de ambas variantes por categoría en validación sintética, manteniendo constante la arquitectura. Se analiza cuál obtiene mejores resultados en cada métrica y si las diferencias son consistentes entre categorías.

B. **H2. Tamaño del coreset en PatchCore.** Aumentar del 1 % al 5 % la proporción de características nominales almacenadas puede mejorar la detección y localización de anomalías, aunque requiere mayor memoria y tiempo de ajuste. La hipótesis se evalúa comparando Image-AUROC y AUPRO de ambas configuraciones por categoría, así como la relación entre el desempeño, el tamaño del banco de características y el tiempo de ajuste.

C. **H3. Capacidad de Doble U-Net.** La variante Large (16–32–64–128) puede mejorar la detección y localización de anomalías frente a Small (16–32–64) gracias a su mayor capacidad, aunque con un costo computacional superior. La hipótesis se evalúa comparando Image-AUROC y AUPRO de ambas variantes por categoría en validación sintética, junto con las curvas de aprendizaje, la mejor época de entrenamiento y los tiempos de ejecución.
D. **H4. Comparación de métodos en defectos reales.** PatchCore obtendrá el mejor desempeño global en detección y localización de anomalías reales, medido mediante Image-AUROC y AUPRO, aunque con diferencias en eficiencia computacional. La hipótesis se evalúa comparando los resultados de los tres métodos en las 15 categorías del conjunto de test, considerando promedios macro, desempeño por categoría, diferencias entre modelos, latencia p95 y tiempos de ajuste. Se prioriza la calidad de detección y localización sobre la velocidad de inferencia.

Las hipótesis H1–H3 se evaluaron mediante validación sintética, comparando dos variantes de cada uno de los tres métodos en las 15 categorías, para un total de 90 configuraciones. A partir de estos resultados, se seleccionó una variante por método y categoría, obteniendo 45 detectores para la evaluación final. Mientras H1–H3 analizan el efecto de las modificaciones dentro de cada arquitectura, H4 compara el desempeño de los tres métodos en el conjunto de test.

Métricas

La evaluación de los modelos se organizó en tres dimensiones: detección de anomalías, localización de defectos y eficiencia computacional. Se establecieron Image-AUROC y AUPRO como métricas principales, mientras que las demás se utilizaron para complementar el análisis de errores, evaluar las predicciones con umbrales específicos y comparar los costos computacionales.

Métricas principales

A. **Image-AUROC (área bajo la curva ROC)**: mide la capacidad del modelo para distinguir imágenes normales de defectuosas mediante diferentes umbrales de clasificación. Se seleccionó como métrica principal de detección porque permite comparar modelos con distintas escalas de puntuación sin depender de un umbral específico. Sus valores

oscilan entre 0 y 1, donde 1 representa una discriminación perfecta y 0,5 equivale al desempeño esperado de una clasificación aleatoria. También se utilizó para seleccionar checkpoints y variantes durante la validación sintética.

B. **AUPRO (área bajo la curva de solapamiento por región)**: evalúa la capacidad de localizar las regiones defectuosas considerando las falsas alarmas por píxel. Se seleccionó como métrica principal de localización porque permite evaluar defectos de diferentes tamaños y analizar el desempeño a través de distintos umbrales. Se calculó hasta una tasa máxima de falsos positivos (FPR) de 0,30 con normalización del área respecto a ese intervalo. Se utilizó para comparar la calidad de localización, sin intervenir en la selección de variantes salvo como criterio de desempate.

Métricas complementarias de detección

A. **Precisión (precision)**: indica qué proporción de las imágenes clasificadas como defectuosas realmente presentan anomalías. Permite evaluar la frecuencia de falsas alarmas.
B. **Sensibilidad (recall)**: mide la proporción de imágenes defectuosas correctamente identificadas. Es relevante para analizar los defectos que podrían pasar inadvertidos.
C. **F1-score**: combina precisión y recall mediante su media armónica. Se utilizó para evaluar el equilibrio entre falsas alarmas y defectos omitidos, así como para calibrar el umbral de clasificación.
D. **Matriz de confusión**: presenta los verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos. Permitió identificar los tipos de errores y complementar la interpretación de las métricas agregadas.

Métricas complementarias de localización

A. **IoU (Intersection over Union):** mide la coincidencia entre la máscara de segmentación predicha y la real, mediante la relación entre sus áreas de intersección y unión.
B. **Dice (Dice Similarity Coefficient):** evalúa el solapamiento entre ambas máscaras y se utilizó para medir la calidad de segmentación y seleccionar el umbral de píxel durante la validación sintética.

Ambas métricas toman valores entre 0 y 1, donde 1 representa una coincidencia perfecta. A diferencia de AUPRO, dependen de un umbral de segmentación específico, por lo que permiten evaluar la calidad de las máscaras binarias generadas por cada modelo.

Métricas de eficiencia computacional

A. **Tiempo de ajuste:** registra el tiempo necesario para preparar cada detector. Incluye el entrenamiento y la validación en Autoencoder y Doble U-Net, mientras que en PatchCore comprende la extracción de características y construcción del banco de memoria. No incluye el costo del preentrenamiento de ResNet18.
B. **Latencia p95:** indica el tiempo por debajo del cual se completa el 95 % de las inferencias. Se seleccionó para evaluar los tiempos de respuesta más lentos y comparar la eficiencia de los modelos.
C. **FPS (Frames per Second)**: mide la cantidad de imágenes procesadas por segundo y permite comparar la capacidad de procesamiento durante la inferencia.

Criterio de selección

La selección de los modelos se realizó exclusivamente mediante validación sintética. Para cada método y categoría se conservó el checkpoint con mayor Image-AUROC y se eligió la variante con mejor resultado en esta métrica, utilizando AUPRO, tiempo de ajuste y nombre de la variante como criterios sucesivos de desempate. Asimismo, se calibraron los umbrales de clasificación y segmentación maximizando F1 y Dice, respectivamente. Tanto las variantes seleccionadas como los umbrales permanecieron fijos durante la evaluación del conjunto de test.

Para determinar el método con mejor desempeño global, se priorizaron Image-AUROC y AUPRO, calculadas como promedios macro de las 15 categorías. También se consideraron la consistencia de los resultados entre categorías y los costos computacionales, medidos mediante tiempo de ajuste, latencia p95 y FPS. La selección final se fundamentó en la calidad de detección y localización, considerando la eficiencia como un factor complementario.

Entorno, presupuesto y reproducibilidad

Los experimentos se ejecutaron en un MacBook con procesador Apple M3 Pro, 36 GB de memoria unificada y aceleración PyTorch MPS. Se documentaron las características del

equipo, las versiones de las bibliotecas y el rendimiento computacional mediante un diagnóstico inicial. Se estableció un presupuesto de 20 minutos por método y categoría (10 minutos por variante), con un máximo de 100 épocas y parada temprana para las redes entrenables. Debido a que el tiempo se verifica entre épocas, 21 ejecuciones superaron ligeramente el límite previsto: 2 de Autoencoder y 19 de Doble U-Net. Estos resultados se conservaron sin modificaciones.

Para facilitar la reproducibilidad, se registraron las configuraciones, semillas, particiones, modelos entrenados, métricas y scripts del proyecto. Sin embargo, las diferencias entre dispositivos y versiones de MPS pueden generar variaciones en los resultados.

Tabla 3. Secuencia documentada de trabajo

Etapa	Actividad	Evidencia producida
I	Auditoría, exploración y particiones	Inventario, manifiestos, notebook de datos
II	Diagnóstico computacional y pruebas piloto	JSON de hardware y benchmarks
III	Implementación y ajuste de 90 variantes	Checkpoints e historiales en results/runs/
IV	Selección en validación sintética	Umbrales y selección de 45 detectores
V	Evaluación única sobre el conjunto de test	45 JSON en results/final/test/
VI	Comparación, análisis de errores e informe	Notebooks de análisis, tablas y figuras

Entrenamiento y validación

Los resultados de esta sección corresponden exclusivamente a la validación sintética y permiten comparar las variantes de cada modelo, analizar su aprendizaje y seleccionar las configuraciones para la evaluación con el conjunto de test.

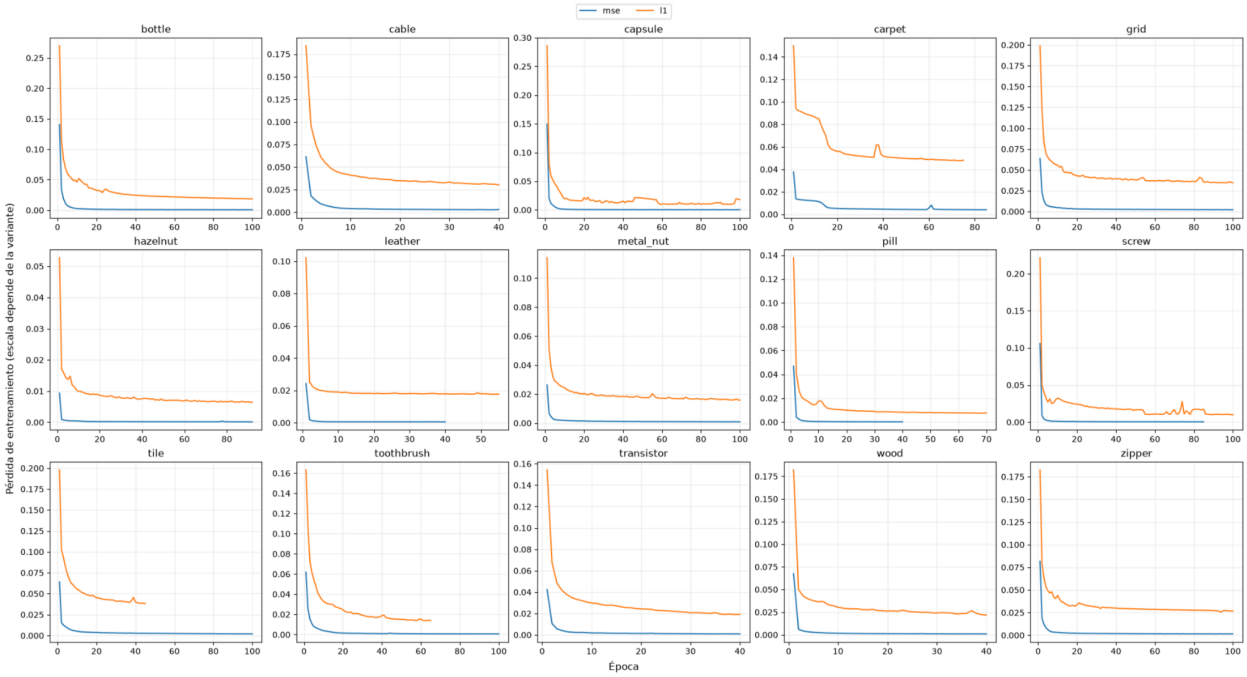
Autoencoder

El Autoencoder aprende a reconstruir imágenes normales y detecta anomalías a partir de las diferencias entre la imagen original y su reconstrucción (Bergmann et al., 2019). Se compararon las funciones de pérdida MSE y L1, manteniendo constantes la arquitectura, las particiones y las condiciones de entrenamiento.

Tabla 4. Autoencoder, promedio de 15 categorías en validación sintética

Variante	Image-AUROC ↑	AUPRO ↑	Tiempo medio de ajuste
MSE	7,005	4,723	252,3 s
L1	6,949	4,881	248,9 s
Diferencia MSE − L1	+0,0056	−0,0158	+3,5 s

Figura 3. Curvas de pérdida de entrenamiento del Autoencoder con funciones MSE y L1



Los resultados muestran que una menor pérdida de reconstrucción no siempre implica una mejor detección de anomalías. Por ello, los checkpoints se seleccionaron según Image-AUROC y no por la pérdida mínima de entrenamiento. MSE obtuvo mejores resultados de detección en 9 de las 15 categorías, aunque su ventaja promedio fue pequeña (+0,0056). En cambio, L1 presentó un mejor AUPRO promedio (+0,0158).

La H1 queda respaldada parcialmente, la función de pérdida influye en el desempeño, pero ninguna variante es superior en ambas métricas. Por esta razón, se seleccionó la mejor configuración del Autoencoder para cada categoría.

PatchCore

PatchCore utiliza una ResNet18 preentrenada para extraer características de imágenes normales y almacenar una muestra representativa mediante coreset (Roth et al., 2022). Durante la inferencia, identifica anomalías según su distancia respecto a las características

almacenadas. Se compararon dos configuraciones que conservan el 1 % y el 5 % de las características extraídas. Como PatchCore no requiere entrenar la red neuronal, el análisis se centró en la calidad de detección, localización y tiempo de construcción del banco de memoria.

Tabla 5. PatchCore, promedio de 15 categorías en validación sintética

Variante	Image-AUROC ↑	AUPRO ↑	Tiempo medio de ajuste
Coreset 1 %	9,160	8,675	4,50 s
Coreset 5 %	9,190	8,703	8,92 s
Diferencia 5 % – 1 %	+0,0030	+0,0027	+4,41 s

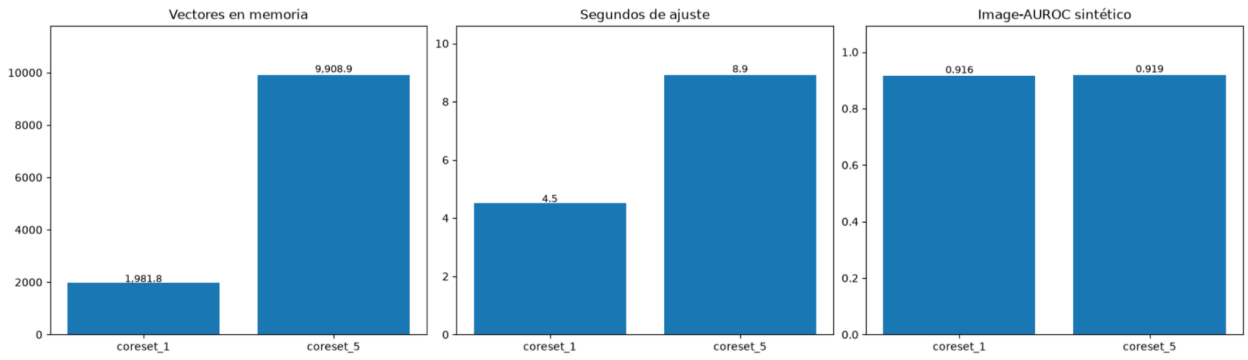


Figura 4. Comparación de Image-AUROC y AUPRO por categoría y relación entre el tamaño del coreset y el tiempo de ajuste.

El coreset del 5 % obtuvo resultados ligeramente superiores en ambas métricas, pero requirió aproximadamente el doble de tiempo de ajuste. Esto indica que almacenar cinco veces más características no genera una mejora proporcional en el desempeño.

La H2 recibe apoyo limitado porque aumentar el coreset mejora ligeramente la detección y localización promedio, pero implica un costo computacional adicional que debe considerarse al seleccionar la variante.

Doble U-Net

El modelo Doble U-Net combina dos redes basadas en la arquitectura U-Net (Ronneberger et al., 2015). La primera reconstruye imágenes normales a partir de entradas alteradas sintéticamente, mientras que la segunda identifica las regiones anómalas comparando la entrada con su reconstrucción. Este enfoque se relaciona conceptualmente con (Zavrtanik et al., 2021).

Se compararon las variantes Small (16–32–64) y Large (16–32–64–128), entrenadas con imágenes normales y anomalías sintéticas, para determinar el efecto de aumentar la capacidad de la arquitectura.

Tabla 6. Doble U-Net, promedio de 15 categorías en validación sintética.

Variante	Image-AUROC ↑	AUPRO ↑	Tiempo medio de ajuste
Small (16–32–64)	9,126	9,355	505,0 s
Large (16–32–64–128)	9,669	9,636	565,2 s
Diferencia Large – Small	+0,0543	+0,0281	+60,2 s

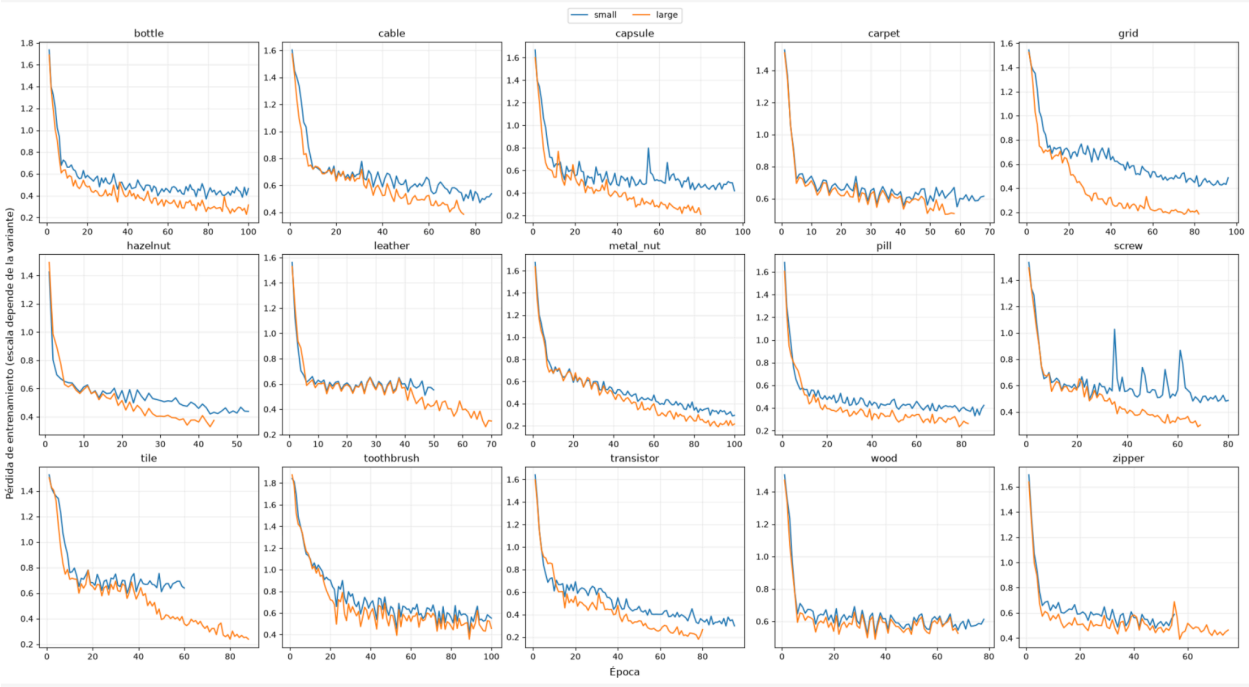


Figura 5. Curvas de pérdida e Image-AUROC de validación para Small y Large

Las curvas de aprendizaje mostraron que la pérdida de entrenamiento podría disminuir sin producir mejoras constantes en Image-AUROC. Por ello, se conservó el checkpoint con mejor desempeño en validación, incluso cuando algunas ejecuciones finalizaron antes de alcanzar las 100 épocas debido al límite de tiempo. La variante Large superó a Small en ambas métricas, con mejoras promedio de 0,0543 en Image-AUROC y 0,0281 en AUPRO, a cambio de aproximadamente un minuto adicional de ajuste por categoría.

La H3 queda respaldada en validación sintética, una mayor capacidad de la arquitectura mejoró la detección y localización. Sin embargo, estos resultados deben contrastarse con

defectos reales, ya que las anomalías utilizadas durante el entrenamiento y la validación fueron generadas artificialmente.

Tabla 7. Efecto principal de las variantes

Hipótesis	Comparación	Diferencia Image-AUROC	Diferencia AUPRO	Decisión
H1	MSE − L1	+0,0056	−0,0158	Sin ganador global consistente
H2	Coreset 5 % − 1 %	+0,0030	+0,0027	Mejora marginal a mayor costo
H3	Large − Small	+0,0543	+0,0281	Large favorecida en validación sintética

Evaluación final y comparación cuantitativa con la línea base

Se evaluaron los 45 detectores seleccionados sobre las 1.725 imágenes del conjunto de test. Las máscaras originales sirvieron exclusivamente para medir localización y no se ajustaron con ellas los parámetros del detector ni los umbrales. Se reportaron métricas por categoría y promedios macro, evitando que las clases con más imágenes dominen el indicador global.

Resultados de detección y localización

Tabla 8. Comparación global de los modelos en el conjunto test

Método	Image-AUROC ↑	AUPRO ↑	Precisión ↑	Recall ↑	F1 ↑	IoU ↑	Dice ↑
Autoencoder (línea base)	6,889	4,367	7,685	7,380	6,832	697	1,253
PatchCore	9,203	9,088	9,042	8,009	8,201	2,383	3,653
Doble U-Net	7,655	5,865	8,994	5,286	6,136	1,156	1,943

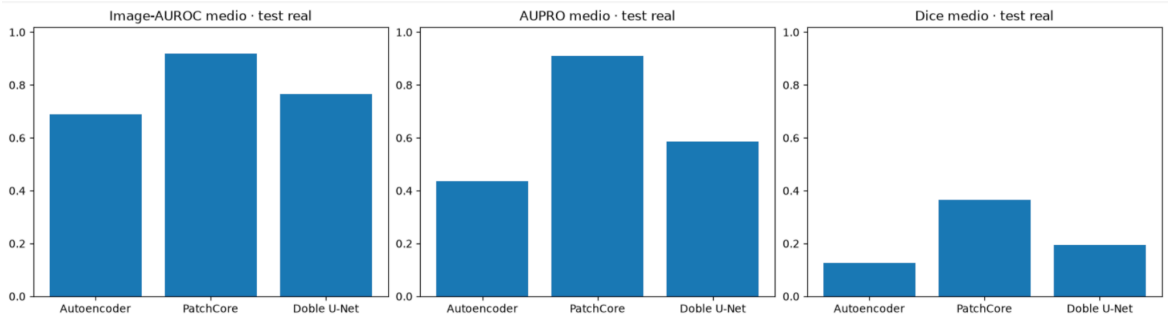


Figura 6. Comparación de Image-AUROC y AUPRO de los tres modelos en test

PatchCore obtuvo el mejor desempeño global, superando al Autoencoder en 0,2314 puntos de Image-AUROC y 0,4721 de AUPRO. Lideró la detección en 11 de las 15 categorías y la localización en todas ellas. Sin embargo, su Dice de 0,3653 evidencia que, aunque identifica

adecuadamente las regiones anómalas a través de distintos umbrales, todavía presenta limitaciones para delimitar los defectos mediante máscaras binarias.

Desempeño por categoría

Tabla 9. Image-AUROC por categoría en el test

Categoría	Autoencoder	PatchCore	Doble U-Net
bottle	824	1,000	948
cable	461	941	760
capsule	574	874	342
carpet	436	932	712
grid	846	696	966
hazelnut	944	1,000	710
leather	767	999	961
metal_nut	406	982	783
pill	533	894	716
screw	784	754	210
tile	773	932	937
toothbrush	739	925	947
transistor	573	955	751
wood	889	981	954
zipper	783	940	787

Los resultados muestran diferencias importantes entre categorías. Aunque PatchCore presentó el mejor desempeño general, Doble U-Net obtuvo resultados superiores en grid, tile y toothbrush, mientras que Autoencoder destacó en screw. Esto evidencia que ningún método es superior en todos los escenarios y que el desempeño depende de las características de los defectos evaluados.

Generalización: validación sintética frente a test real

Tabla 10. Comparación del desempeño entre validación sintética y test

Modelo	Image-AUROC validación	Image-AUROC test	Cambio	AUPRO validación	AUPRO test	Cambio
Autoencoder	7,116	6,889	−0,0226	4,795	4,367	−0,0428
PatchCore	9,195	9,203	+0,0008	8,699	9,088	+0,0389
Doble U-Net	9,698	7,655	−0,2043	9,583	5,865	−0,3718

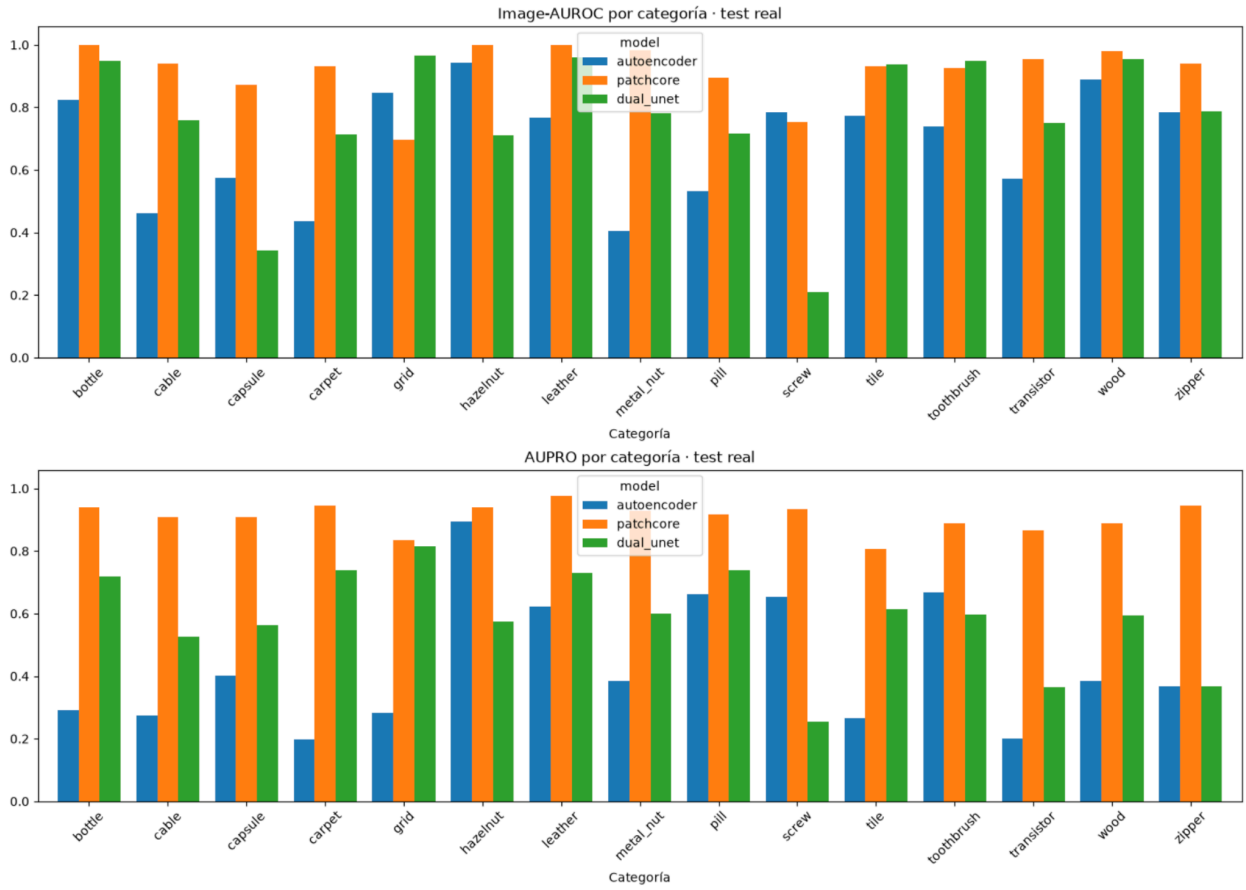


Figura 7. Comparación de Image-AUROC y AUPRO entre validación sintética y test

PatchCore mantuvo un desempeño estable entre ambas evaluaciones, mientras que Doble U-Net presentó una disminución considerable, especialmente en localización (−0,3718 AUPRO). Esta diferencia podría relacionarse con las características de las anomalías sintéticas utilizadas durante el entrenamiento, que no representan la diversidad de defectos reales.

Estos resultados muestran que un desempeño elevado en validación sintética no garantiza una generalización equivalente al test real, especialmente en modelos entrenados para reconocer alteraciones artificiales.

Eficiencia computacional

Tabla 11. Comparación de eficiencia de los modelos seleccionados

Modelo	Tiempo medio de ajuste	Latencia p95 media	FPS medio
Autoencoder	252,6 s	3,50 ms	347,6
PatchCore	8,4 s	13,20 ms	89,0

Doble U-Net	547,5 s	9,33 ms	149,1

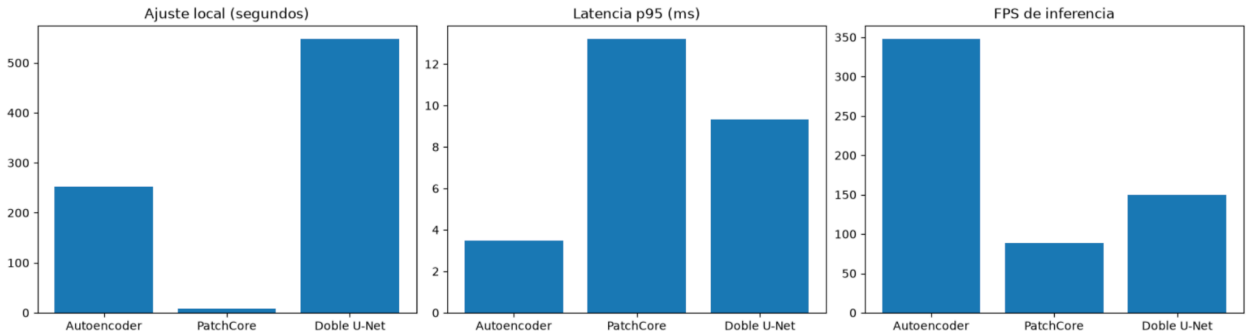


Figura 8. Comparación del tiempo de ajuste, latencia p95 y FPS de los tres modelos

PatchCore presentó el menor tiempo de ajuste, aunque su latencia de inferencia fue la más alta. Por el contrario, Autoencoder obtuvo la menor latencia y el mayor FPS, mientras que Doble U-Net requirió el mayor tiempo de entrenamiento.

Estos resultados evidencian diferencias entre los modelos en términos de calidad y eficiencia computacional. Cabe señalar que el tiempo de ajuste de PatchCore no incluye el preentrenamiento de ResNet18 y que las mediciones de inferencia no representan el rendimiento de un sistema industrial completo.

Contraste de H4 y selección del método

Los resultados respaldan H4, ya que PatchCore obtuvo el mejor desempeño global en las dos métricas principales. Frente al Autoencoder, mejoró Image-AUROC en 0,2314 puntos y AUPRO en 0,4721; frente a Doble U-Net, las diferencias fueron de 0,1548 y 0,3223, respectivamente. Aunque PatchCore presentó una latencia p95 aproximadamente 3,8 veces mayor que Autoencoder, alcanzó los mejores resultados de detección y localización, además del menor tiempo de ajuste local.

Por tanto, se selecciona PatchCore como el método más adecuado para los objetivos del estudio, priorizando la calidad de detección y localización. No obstante, Autoencoder representa una alternativa cuando la velocidad de inferencia constituye el requisito principal.

Análisis de errores

Para complementar las métricas globales, se analizaron visualmente los resultados de las categorías bottle, tile, wood y carpet. Se compararon las imágenes originales, las máscaras reales, los mapas de anomalía y las máscaras predichas, considerando casos de clasificación correcta e incorrecta. Este análisis permitió identificar falsas alarmas, defectos omitidos y errores de localización que no siempre se reflejan en las métricas generales.

Tabla 12. Casos representativos de las matrices de confusión

Categoría y método	VP	FP	FN	VN	Interpretación
bottle / PatchCore	63	0	0	20	Clasificación correcta de las 83 imágenes
bottle / Autoencoder	41	3	22	17	Numerosos defectos no detectados
bottle / Doble U-Net	48	0	15	20	Sin falsas alarmas, pero con 15 defectos omitidos
tile / Autoencoder	84	33	0	0	Todas las imágenes clasificadas como anómalas
tile / PatchCore	84	31	0	2	Detecta todos los defectos, pero genera falsas alarmas
tile / Doble U-Net	60	1	24	32	Menos falsas alarmas, pero más defectos omitidos
carpet / PatchCore	89	28	0	0	Detecta todos los defectos, pero clasifica incorrectamente las imágenes normales
wood / PatchCore	59	8	1	11	Buen desempeño relativo, con algunos errores

En bottle, PatchCore clasificó correctamente todas las imágenes, mientras que Autoencoder y Doble U-Net omitieron 22 y 15 defectos, respectivamente. Sin embargo, una clasificación correcta no garantiza una segmentación precisa, por lo que también es necesario examinar las máscaras predichas.

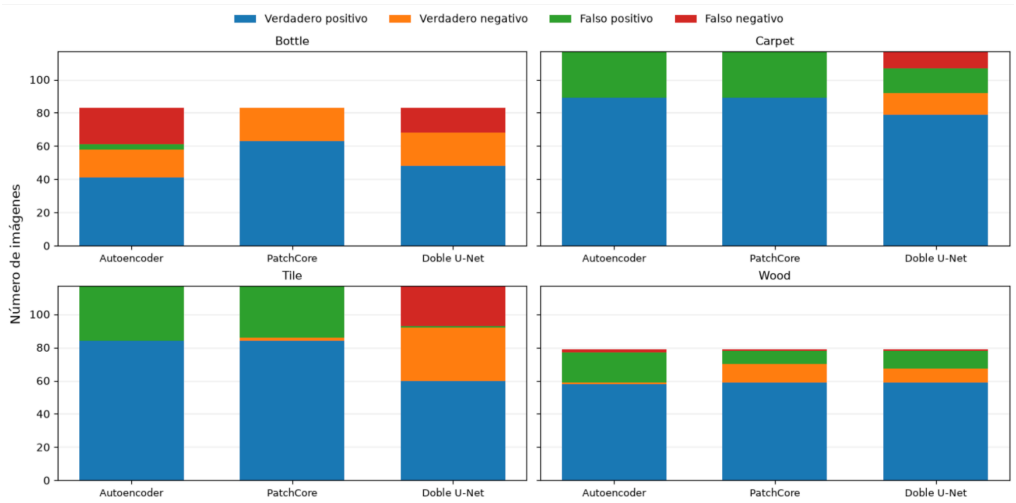


Figura 9. Aciertos y errores de clasificación de los tres modelos en cuatro categorías

Los resultados evidencian diferencias importantes entre categorías. PatchCore destaca por su capacidad de detección, pero presenta dificultades para reconocer imágenes normales en algunas texturas, especialmente carpet y tile. Doble U-Net reduce las falsas alarmas en estas categorías, aunque puede omitir más defectos.

La selección de PatchCore se justifica por el desempeño agregado, pero los errores de tile y carpet demuestran que el umbral calibrado con defectos sintéticos no garantiza especificidad adecuada en todas las texturas. La localización binaria también necesita una evaluación independiente de la clasificación global.

Limitaciones y oportunidades de mejora

Aunque los resultados permiten comparar los tres métodos bajo un protocolo común, se identificaron limitaciones relacionadas con la generalización, la calibración de umbrales, la eficiencia computacional y la reproducibilidad. La siguiente tabla resume los principales hallazgos y las posibles mejoras para investigaciones futuras.

Tabla 13. Limitaciones identificadas y oportunidades de mejora

Evidencia o limitación	Consecuencia	Oportunidad de mejora
Bajo Image-AUROC del Autoencoder en varias categorías	Dificultades para distinguir imágenes normales y defectuosas	Explorar características perceptuales y otros métodos de reconstrucción
Caída de Doble U-Net en test real (−0,2043 Image-AUROC y −0,3718 AUPRO)	Generalización limitada frente a defectos reales	Diversificar anomalías sintéticas y realizar validación externa
Falsos positivos de PatchCore en tile y carpet	Calibración poco consistente entre categorías	Investigar nuevos criterios de calibración con datos independientes
Valores bajos de Dice	Delimitación imprecisa de regiones defectuosas	Evaluar mayor resolución, posprocesamiento y calibración de segmentación
Mayor latencia p95 de PatchCore	Menor velocidad de inferencia	Optimizar la búsqueda de vecinos y el tamaño del coreset
Ausencia de mediciones comparables de memoria pico	Evaluación incompleta de recursos computacionales	Incorporar mediciones de memoria en futuros experimentos
Preentrenamiento de ResNet18 en ImageNet	Diferencias en los recursos utilizados previamente por los modelos	Diferenciar los costos de preentrenamiento, ajuste e inferencia
Implementación propia de AUPRO	Posibles diferencias respecto a implementaciones de referencia	Contrastar resultados con una implementación de referencia

Un único dataset, equipo y semilla experimental	Generalización y reproducibilidad limitadas	Repetir experimentos con distintas semillas, equipos y datasets

Conclusiones

El estudio permitió comparar el Autoencoder como línea base frente a PatchCore y Doble U-Net en 15 categorías de inspección visual industrial. Se aplicó un protocolo experimental común, con particiones fijas, selección de variantes mediante validación sintética y evaluación independiente sobre el test. En total, se realizaron 90 ajustes y 45 evaluaciones finales, garantizando la trazabilidad de los resultados.

La hipótesis H1 evidenció que la función de pérdida influye en el desempeño del Autoencoder, aunque ninguna variante fue superior en ambas métricas. MSE obtuvo un Image-AUROC promedio de 0,7005 frente a 0,6949 de L1, mientras que L1 alcanzó un mejor AUPRO (0,4881 frente a 0,4723). Esto indica que la elección de la función de pérdida puede favorecer la detección o la localización, sin que exista una configuración superior en todos los casos.

La hipótesis H2 mostró que aumentar del 1 % al 5 % las características almacenadas en PatchCore produjo mejoras pequeñas en Image-AUROC (+0,0030) y AUPRO (+0,0027), mientras que el tiempo medio de ajuste prácticamente se duplicó. Por tanto, incrementar el tamaño del banco de características no genera mejoras proporcionales en el desempeño y debe evaluarse considerando su costo computacional.

La hipótesis H3 mostró que la variante Large de Doble U-Net superó a Small en validación sintética, con mejoras de 0,0543 en Image-AUROC y 0,0281 en AUPRO. Sin embargo, este desempeño no se mantuvo frente a defectos reales, donde el modelo seleccionado disminuyó de 0,9698 a 0,7655 en Image-AUROC y de 0,9583 a 0,5865 en AUPRO. Esto evidencia que una mayor capacidad de la arquitectura puede mejorar los resultados en validación sintética sin garantizar una generalización equivalente.

La hipótesis H4 quedó respaldada por los resultados de la evaluación con el conjunto de test, donde PatchCore superó al Autoencoder en 0,2314 puntos de Image-AUROC y 0,4721 de AUPRO, además de superar a Doble U-Net en ambas métricas. Obtuvo el mejor

Image-AUROC en 11 de las 15 categorías y lideró AUPRO en todas ellas, consolidándose como el método con mejor desempeño global en detección y localización.

En términos de eficiencia computacional, Autoencoder presentó la menor latencia p95 media (3,50 ms), PatchCore el menor tiempo de ajuste local (8,4 s) y Doble U-Net el mayor tiempo de entrenamiento. Aunque PatchCore obtuvo los mejores resultados de calidad, no fue el más rápido durante la inferencia.

En conclusión, PatchCore, basado en una ResNet18 preentrenada y un banco de características normales, presentó el mejor desempeño global para detectar y localizar anomalías reales en MVTec AD. Las diferencias entre validación sintética y test real también resaltan la importancia de evaluar los modelos con datos independientes y complementar las métricas globales con análisis por categoría e inspección visual de errores.

Referencias bibliográficas

Bergmann, P., Fauser, M., Sattlegger, D., & Steger, C. (2019). MVTec AD — A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection. *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 9584–9592. https://doi.org/10.1109/CVPR.2019.00982

Li, C.-L., Sohn, K., Yoon, J., & Pfister, T. (2021). *Cutpaste: Self-supervised learning for anomaly detection and localization*. 9659–9669.

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. En N. Navab, J. Hornegger, W. M. Wells, & A. F. Frangi (Eds.), *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (pp. 234–241). Springer International Publishing.

Roth, K., Pemula, L., Zepeda, J., Schölkopf, B., Brox, T., & Gehler, P. (2022). *Towards total recall in industrial anomaly detection*. 14298–14308.

Zavrtanik, V., Kristan, M., & Skočaj, D. (2021). *DRÆM–A discriminatively trained reconstruction embedding for surface anomaly detection*. 8310–8319.